

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Árboles de decisión en la precisión de sistemas de clasificación	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	4
1.2.1.	Funcionamiento y Construcción	4
1.2.2.	Algoritmos Basados en Árboles de Decisión	4
1.2.3.	Factores que Influyen en la Precisión	5
1.3.	Metodología	6
1.3.1.	Estrategia de búsqueda y selección	6
1.3.2.	Criterios de inclusión y exclusión	6
1.3.3.	Procedimiento de análisis y extracción de variables	7
1.3.4.	Evidencia experimental	7
1.4.	Análisis de la Literatura	8
1.4.1.	El fin del paradigma voraz	8
1.4.2.	Influencia de la dimensionalidad de los nodos	9
1.4.3.	Hibridación y adaptabilidad	9
1.4.4.	Factores que afectan la precisión	10
1.4.5.	Síntesis integradora	11
1.5.	Conclusiones	13

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Árboles de decisión en la precisión de sistemas de clasificación

Autor: Richard Vicente Cajas Riofrío richard.cajas@unl.edu.ec
Técnica asignada: Árboles de decisión

1.1. Introducción

En el panorama actual del aprendizaje automático y la minería de datos, la clasificación se ha consolidado como una tarea fundamental que consiste en identificar a qué categoría predefinida pertenece una nueva instancia basándose en un conjunto de entrenamiento. [1–3] La eficacia de estos sistemas se mide principalmente a través de su precisión, una métrica crítica en dominios donde los errores pueden tener consecuencias significativas, como en el diagnóstico médico, la detección de fraudes financieros o la gestión de recursos en sistemas embebidos. [4–6]

Dentro de la plétora de algoritmos de clasificación, los árboles de decisión (DT) destacan como una de las herramientas más exitosas y ampliamente utilizadas [2] Su popularidad radica en su estructura jerárquica, que emula el razonamiento humano mediante una secuencia de preguntas condicionales, lo que los hace intrínsecamente interpretables y fáciles de auditar. [6,7] A diferencia de los modelos de "caja negra", como las redes neuronales profundas, los DT permiten visualizar el camino seguido desde la raíz hasta la hoja para cada predicción. [8,9]

Sin embargo, alcanzar una alta precisión con árboles de decisión presenta desafíos técnicos considerables. Los algoritmos tradicionales a menudo sufren de sobreajuste (overfitting), generando estructuras excesivamente complejas que capturan el ruido de los datos en lugar de las tendencias generales. [9,10] Además, la naturaleza "voraz" (greedy) de los inductores clásicos, que buscan la pureza local en cada partición, no garantiza la obtención de un árbol globalmente óptimo en términos de precisión y tamaño. [10]

El estudio de la precisión en los DT es esencial debido a la creciente demanda de modelos que no solo sean exactos, sino también explicables bajo nuevas regulaciones de inteligencia artificial. [11] Este documento analiza cómo diversos factores desde la elección del algoritmo de inducción hasta las estrategias de poda y el manejo de flujos de datos influyen en la capacidad predictiva del sistema. La pregunta de investigación que guía este trabajo es: ¿Cómo influyen los árboles de decisión en la precisión de los sistemas de clasificación? A través de una revisión sistemática de la literatura técnica proporcionada, se sintetizarán las evidencias sobre algoritmos clásicos y modernos, factores de rendimiento y nuevas arquitecturas como los árboles bivariados o los optimizados mediante programación dinámica.

1.2. Fundamentos Teóricos

Sistemas de Clasificación Un clasificador es una función que mapea un vector de características de entrada a una etiqueta de clase discreta. [12,13] Esta tarea puede ser binaria (dos clases) o multiclase. [3,14] La precisión de estos sistemas es una medida de la concordancia entre las etiquetas predichas y las reales. [14,15]

Métricas de Evaluación Para cuantificar el desempeño, se utilizan diversas métricas derivadas de la matriz de confusión: [16,17]

- **Accuracy (Exactitud):** Proporción de predicciones correctas sobre el total. [18,19]
- **Precision (Precisión):** Capacidad del modelo para no etiquetar como positiva una muestra negativa. [19,20]
- **Recall (Exhaustividad/Sensibilidad):** Capacidad para detectar todas las muestras positivas.
- **F1-Score:** Media armónica entre precisión y recall, útil en conjuntos desbalanceados. [4,20]
- **ROC-AUC:** El área bajo la curva de la característica operativa del receptor, que evalúa la capacidad de discriminación del modelo independientemente del umbral. [18,21,22]

Árboles de Decisión Un árbol de decisión es un modelo predictivo representado gráficamente como una estructura de árbol invertida. [1,3]

- **Componentes Principales:**
- **Root Node (Nodo Raíz):** El punto de partida que contiene el atributo más discriminativo. [1,20]
- **Internal Nodes (Nodos Internos):** Representan pruebas sobre atributos específicos. [20,23]
- **Leaf Nodes (Nodos Hoja):** Nodos terminales que asignan la etiqueta de clase final o un valor de regresión. [12,20,24]

1.2.1. Funcionamiento y Construcción

El proceso de construcción de un árbol de decisión se basa en el particionamiento recursivo del espacio de características. [20,24] En cada nodo, el algoritmo selecciona el atributo y el umbral que mejor dividen los datos en subgrupos homogéneos o “puros”. [1,25] Este procedimiento continúa hasta alcanzar un criterio de parada, como la pureza total del nodo, una profundidad máxima predefinida o un número mínimo de muestras por nodo. [11,12]

1.2.2. Algoritmos Basados en Árboles de Decisión

Existen diversas implementaciones de árboles de decisión que difieren principalmente en el criterio utilizado para seleccionar los atributos durante el proceso de partición. La Tabla 1.1 presenta una comparación de los algoritmos clásicos más utilizados.

Tabla 1.1: Comparativa de algoritmos clásicos de árboles de decisión

Algoritmo	Criterio de Selección	Tipo de Atributos	Características Clave
ID3	Ganancia de Información	Categoricos	Presenta dificultades con atributos que poseen un gran número de valores distintos.
C4.5	Ratio de Ganancia	Continuos y categoricos	Permite el manejo de valores faltantes e incorpora técnicas de poda.
CART	Índice Gini	Continuos y categoricos	Genera árboles binarios y puede emplearse tanto en clasificación como en regresión.

Random Forest (Bosque Aleatorio)

Random Forest es una extensión de los árboles de decisión que mejora significativamente la precisión mediante técnicas de aprendizaje por conjunto (*ensemble learning*). Este método entrena múltiples árboles independientes utilizando subconjuntos aleatorios de datos y características mediante el proceso conocido como *bagging*. [12, 13, 26] Posteriormente, combina las predicciones individuales a través de votación mayoritaria, reduciendo la varianza y el error de clasificación en comparación con un único árbol de decisión. [18]

1.2.3. Factores que Influyen en la Precisión

La precisión de un árbol de decisión no depende únicamente del algoritmo utilizado, sino también de diversos factores relacionados con los datos y la configuración del modelo:

- **Calidad de los datos:** La presencia de ruido, inconsistencias o valores faltantes puede afectar negativamente las particiones realizadas durante las primeras etapas de construcción del árbol. [26, 27]
- **Sobreajuste (*Overfitting*):** Se produce cuando el árbol alcanza una profundidad excesiva y memoriza los datos de entrenamiento, reduciendo su capacidad de generalización sobre datos nuevos. [9, 10, 18]
- **Poda (*Pruning*):** Técnica utilizada para reducir el sobreajuste mediante la eliminación de ramas que aportan poca capacidad predictiva. [7, 9]
- **Selección de atributos:** La eliminación de variables irrelevantes o redundantes puede mejorar la precisión y disminuir la complejidad computacional del modelo. [3, 26]
- **Tamaño del conjunto de entrenamiento:** El crecimiento del árbol suele estar relacionado con la cantidad de datos disponibles, pudiendo incrementar la complejidad sin necesariamente mejorar la precisión. [7]
- **Desbalance de clases:** Cuando una clase predomina significativamente sobre las demás, el árbol tiende a favorecer la clase mayoritaria, disminuyendo métricas como el *recall* de las clases minoritarias. [19, 21]

1.3. Metodología

La presente investigación se constituye como una revisión sistemática cualitativa y cuantitativa de carácter profundo, diseñada para desentrañar la complejidad de los mecanismos que rigen el desempeño de los árboles de decisión (DT). El enfoque metodológico se aleja de la descripción superficial para centrarse en un análisis crítico de la arquitectura algorítmica y su impacto directo en la capacidad predictiva de los sistemas de clasificación. [7, 23]

1.3.1. Estrategia de búsqueda y selección

El proceso de búsqueda bibliográfica se ejecutó mediante una arquitectura de consultas multi-etapa, orientada a capturar tanto la base fundacional de la inducción de árboles como las innovaciones de vanguardia publicadas hasta 2025 [10, 20]. Se seleccionaron repositorios académicos de alto impacto para garantizar la robustez de la evidencia: ACM Digital Library por su liderazgo en teoría de computación y algoritmos de optimización [7, 10]; IEEE Xplore por su estandarización en aplicaciones de ingeniería y sistemas electrónicos [23, 28]; Springer por su profundidad en minería de datos y lógica difusa [20, 23]; y ScienceDirect (Elsevier) por su enfoque en aplicaciones prácticas y toxicología computacional. [20, 21]

La selección de estos repositorios se justifica metodológicamente por la necesidad de triangular datos provenientes de diversas escuelas de pensamiento en Machine Learning. Por ejemplo, mientras que ACM proporciona las bases para los árboles bivariados y optimizaciones dinámicas [7, 10], IEEE ofrece el marco para la implementación en tiempo real y hardware embebido. [6, 13] Los descriptores utilizados, tales como *decision tree accuracy*, *non-greedy induction*, *bivariate decision trees*, *concept drift* y *fairness-guided pruning*, representan los vectores críticos identificados por la literatura para responder a la pregunta de investigación. [7, 9–11]

Estos términos permiten una disección técnica de la precisión. El descriptor *non-greedy induction* facilita explorar cómo la superación del paradigma de partición local impacta en la exactitud global [10], mientras que *bivariate trees* analiza cómo la modelación de correlaciones entre características reduce el error de generalización. [7] La relevancia de los descriptores radica en su capacidad para mapear los factores que tradicionalmente degradan la precisión, como el sobreajuste (*overfitting*) y la fragmentación de datos, permitiendo así una respuesta rigurosa sobre la influencia de estos modelos en los sistemas de clasificación contemporáneos. [8, 9]

1.3.2. Criterios de inclusión y exclusión

La validez y confiabilidad de esta revisión se sustentan en criterios de elegibilidad estrictos. Se incluyeron artículos que: (a) presentaran validaciones empíricas utilizando conjuntos de datos estándar como UCI, KDD-99 o ISOT, garantizando la comparabilidad de resultados [1, 5, 29]; (b) reportaran métricas derivadas de la matriz de confusión, tales como Accuracy, F1-Score y ROC-AUC [17, 20]; y (c) realizaran comparativas directas entre paradigmas de inducción, por ejemplo, CART versus C4.5 o enfoques *greedy* frente a modelos basados en MDP. [7, 29]

Metodológicamente, estos criterios aseguran que la evidencia recopilada no esté sesgada por implementaciones *ad hoc* o datos no verificables. Asimismo, la inclusión de estudios relacionados con privacidad diferencial y encriptación homomórfica responde a la necesidad de evaluar la precisión bajo restricciones modernas de seguridad y privacidad. [1, 23]

Por el contrario, se excluyeron documentos de naturaleza exclusivamente teórica que carecieran de validación experimental [25], así como investigaciones que no estuvieran centradas en tareas de clasificación supervisada o semi-supervisada. Este rigor metodológico evita la selección sesgada de resultados y fortalece la capacidad de generalización de las conclusiones obtenidas. [5]

1.3.3. Procedimiento de análisis y extracción de variables

Para cada estudio seleccionado se realizó un análisis multidimensional sustentado en cuatro variables consideradas determinantes para la precisión de los sistemas de clasificación.

Arquitectura del algoritmo

Se distinguieron árboles univariados, bivariados y multivariados. Esta variable resulta fundamental porque define la forma de las fronteras de decisión. Los árboles bivariados pueden capturar correlaciones entre atributos que los modelos univariados suelen representar mediante estructuras excesivamente profundas, lo que repercute directamente en la precisión y capacidad de generalización. [7, 29]

Estrategia de inducción

Se compararon algoritmos basados en inducción voraz (*greedy*) frente a enfoques de optimización global, incluyendo Programación Dinámica basada en Procesos de Decisión de Markov (MDP) y Alternating Tree Optimization (TAO). Esta variable es crítica porque la naturaleza local de los algoritmos tradicionales puede conducir a soluciones subóptimas que limitan la exactitud alcanzable. [7, 10]

Dataset y contexto

La precisión de un árbol de decisión depende significativamente del contexto de aplicación. Se analizaron escenarios asociados a flujos de datos (*data streams*) sujetos a *concept drift*, conjuntos de datos médicos desbalanceados y datos protegidos mediante cifrado homomórfico. [5, 17, 30] Esta variable permite explicar las diferencias de rendimiento observadas entre dominios.

Métricas de rendimiento

Se estandarizó la extracción de métricas tales como Accuracy, Precision, Recall y F1-Score. [19, 31] Adicionalmente, el área bajo la curva ROC (AUC) fue considerada como un indicador robusto del desempeño en aplicaciones críticas, particularmente en sistemas de apoyo al diagnóstico médico. [18, 21]

1.3.4. Evidencia experimental

La evidencia experimental sintetizada revela tendencias divergentes y coincidencias significativas. En conjuntos de datos médicos, el algoritmo C4.5 presenta una superioridad consistente sobre CART e ID3, alcanzando valores de exactitud cercanos al 95.61 % en el dataset WBCD debido a su capacidad para manejar atributos continuos y aplicar mecanismos de poda más efectivos. [5, 29]

Sin embargo, la comparación con modelos híbridos como NBTree demuestra que la incorporación de clasificadores Naive Bayes en las hojas puede elevar significativamente el área bajo la curva ROC, superando limitaciones asociadas a la fragmentación de datos observada en árboles convencionales. [8, 17]

Una tendencia particularmente relevante emerge al comparar enfoques de inducción voraz con métodos de optimización global. El marco DPDT alcanza una precisión del 100 % en problemas XOR y supera consistentemente a CART en conjuntos de datos complejos como KDD-99, evidenciando que la optimización no-voraz constituye un factor determinante para alcanzar niveles superiores de exactitud. [10]

Asimismo, los árboles bivariados han demostrado reducir el tamaño de los modelos hasta diecisiete veces manteniendo o incluso incrementando la precisión en conjuntos de datos como

Segment y MiniBooNE. [7] Esta reducción favorece la interpretabilidad y disminuye el riesgo de sobreajuste.

En el ámbito de la seguridad y privacidad, diversos estudios indican que es posible mantener niveles de precisión comparables a los obtenidos mediante implementaciones tradicionales de `scikit-learn`, incluso sobre datos cifrados, mediante el empleo de funciones de paso suaves y aproximaciones polinomiales de alto grado. [1]

Finalmente, el análisis comparativo entre Random Forest y árboles individuales confirma que los métodos de ensamblado reducen la varianza y mejoran la precisión global. No obstante, estas ventajas suelen acompañarse de una pérdida de interpretabilidad, lo que ha impulsado el desarrollo de modelos como MetaSilvae para equilibrar precisión, robustez y explicabilidad. [12, 26]

1.4. Análisis de la Literatura

La evidencia científica recopilada permite una síntesis crítica sobre la evolución estructural y funcional de los árboles de decisión (DT), marcando un punto de inflexión en la forma en que estos modelos influyen en la precisión de los sistemas de clasificación contemporáneos. El análisis se articula en torno a la superación de las limitaciones de los algoritmos clásicos y la exploración de nuevas arquitecturas de nodos que optimizan el compromiso entre interpretabilidad y exactitud predictiva.

1.4.1. El fin del paradigma voraz

Históricamente, la inducción de árboles de decisión ha estado dominada por algoritmos de partición recursiva voraz (*greedy*) como CART e ID3, los cuales seleccionan divisiones basadas exclusivamente en criterios de pureza local inmediata, tales como el índice Gini o la entropía de Shannon. [1, 12] Si bien este enfoque destaca por su eficiencia computacional y escalabilidad a conjuntos de datos masivos, la literatura técnica coincide en que suele producir estructuras globalmente subóptimas que limitan la precisión máxima del sistema. Una síntesis comparativa entre estos métodos tradicionales y las propuestas de optimización global, como los Árboles de Decisión de Programación Dinámica (DPDT) y la Optimización Alternada de Árboles (TAO), revela diferencias significativas en el rendimiento predictivo y la capacidad de generalización. [7, 10]

La superioridad de los métodos no voraces se manifiesta de forma drástica en problemas no lineales complejos, como el caso patológico de la compuerta lógica XOR. Mientras que CART alcanza una exactitud de entrenamiento de apenas el 75.88 % debido a que su raíz voraz no puede anticipar la interacción de variables, algoritmos como DPDT, que formulan la inducción como un Proceso de Decisión de Markov (MDP), logran una precisión perfecta del 100 % al optimizar globalmente la pérdida de entrenamiento regularizada. En conjuntos de datos estándar, esta tendencia se mantiene; por ejemplo, en el dataset *Bean*, DPDT alcanzó un 85.3 % de exactitud frente al 77.7 % de CART, demostrando que la optimización global es capaz de recuperar una ganancia de precisión significativa que los métodos locales ignoran. [10]

En términos de complejidad computacional, los métodos globales presentan tradicionalmente un costo elevado. Sin embargo, la evidencia reciente indica que DPDT logra alcanzar el 99 % de la precisión óptima realizando entre dos y cuatro órdenes de magnitud menos operaciones que los resolvedores exactos convencionales, posicionándose como un punto medio eficiente entre la rapidez de CART y la exhaustividad de los métodos de búsqueda completa [10].

Por otro lado, la capacidad de generalización de estos nuevos paradigmas es sustancialmente superior. Estudios recientes muestran que DPDT aprende árboles más precisos que CART y STreeD tanto en datos numéricos como categóricos, manteniendo una robustez estructural que

evita el crecimiento descontrolado del número de nodos conforme aumenta el tamaño de la muestra, fenómeno asociado frecuentemente con el sobreajuste en algoritmos voraces. [7, 10]

1.4.2. Influencia de la dimensionalidad de los nodos

Un factor determinante en la precisión de los sistemas de clasificación es la arquitectura del nodo de decisión. Los árboles univariados tradicionales, que operan sobre una sola característica por nivel, presentan limitaciones intrínsecas al modelar correlaciones entre variables, obligando al modelo a construir fronteras de decisión escalonadas y estructuras excesivamente profundas que degradan la capacidad de generalización. La transición hacia árboles bivariados y multivariados permite capturar estas interacciones multidimensionales, influyendo directamente en la reducción del error de clasificación. [7]

El impacto de las correlaciones entre variables se evidencia en estudios comparativos sobre conjuntos de datos de alta dimensionalidad. En el dataset MiniBooNE, la implementación de árboles bivariados mediante TAO no solo superó la exactitud de los árboles univariados, sino que produjo un modelo diecisiete veces más pequeño. Esta reducción masiva en la complejidad estructural constituye un indicador importante de calidad, ya que un modelo más compacto y preciso refleja una representación más eficiente de la estructura latente de los datos. [7]

De manera similar, en el dataset Segment, un árbol bivariado alcanzó una tasa de error del 2.59 % utilizando únicamente 25 nodos, mientras que CART requirió 128 nodos para obtener un error superior del 3.99 %. Estos resultados sugieren que la incorporación de múltiples atributos en una misma decisión mejora la capacidad discriminativa sin necesidad de incrementar excesivamente la profundidad del árbol. [7]

La evidencia procedente del ámbito médico refuerza esta hipótesis. En el dataset Breast Cancer, un árbol bivariado optimizado logró representar el diagnóstico mediante únicamente cinco reglas de decisión y un error cercano al 2 %, mientras que los modelos univariados requirieron dieciséis reglas para alcanzar errores superiores al 6 %. Esta diferencia se explica porque el nodo bivariado actúa como una característica derivada capaz de capturar relaciones conjuntas entre atributos clínicos relevantes. [6, 7, 13]

Desde una perspectiva computacional, la reducción de profundidad también resulta especialmente valiosa en aplicaciones de tiempo real y sistemas embebidos. Cuando las restricciones de latencia son estrictas, un árbol más compacto puede ofrecer tiempos de inferencia menores manteniendo niveles de precisión competitivos frente a enfoques más complejos, incluyendo algunos modelos de aprendizaje profundo aplicados a datos estructurados. [7]

La literatura también destaca que la dimensionalidad de los nodos influye en la interpretabilidad. Aunque los árboles bivariados y multivariados incrementan ligeramente la complejidad de cada regla individual, la reducción del número total de nodos y ramas suele compensar esta dificultad, generando modelos más compactos y comprensibles para los expertos del dominio. [7]

Asimismo, la capacidad de capturar correlaciones entre atributos reduce la necesidad de transformaciones previas de características, permitiendo que el propio árbol incorpore relaciones complejas directamente durante el proceso de inducción. Esto contribuye a disminuir la pérdida de información y mejora la robustez frente a ruido y redundancia en los datos. [7]

En conjunto, los resultados revisados sugieren que la influencia de los árboles de decisión en la precisión de los sistemas de clasificación ha evolucionado desde una dependencia exclusiva de la profundidad hacia una dependencia de la optimización estructural. La incorporación de estrategias de inducción global y nodos bivariados representa actualmente uno de los avances más relevantes para mejorar simultáneamente exactitud, robustez e interpretabilidad. [7, 10]

1.4.3. Hibridación y adaptabilidad

La literatura técnica identifica la hibridación como una estrategia crítica para superar las limitaciones intrínsecas de los modelos puros, especialmente el problema de la fragmentación

de datos y la suposición de independencia de atributos. El algoritmo NBTree ejemplifica esta tendencia al integrar nodos de decisión univariados con clasificadores Naive Bayes en las hojas, permitiendo modelar interacciones complejas en subconjuntos de datos donde un árbol tradicional sufriría de escasez de muestras para realizar estimaciones fiables. La evidencia experimental demuestra que NBTree supera consistentemente a C4.5 en conjuntos de datos de gran escala como Adult y Shuttle, logrando una precisión promedio del 84.47 % frente al 81.91 % de los modelos puros. Este comportamiento se atribuye a que el componente bayesiano actúa como un estimador paramétrico robusto cuando la independencia entre atributos no se cumple estrictamente. [8]

En términos de estabilidad y robustez, los Bosques Aleatorios (*Random Forest*, RF) se consolidan como uno de los enfoques más efectivos para reducir la varianza mediante el ensamblaje de múltiples árboles entrenados sobre subconjuntos aleatorios de características [13, 18]. Sin embargo, investigaciones recientes han propuesto arquitecturas más sofisticadas orientadas a mejorar la resiliencia frente a perturbaciones adversariales. En este contexto, MetaSilvae introduce un marco de entrenamiento genético que optimiza simultáneamente la exactitud y la robustez del modelo. [12]

Mientras que un Random Forest convencional puede presentar una estabilidad prácticamente nula frente a determinadas perturbaciones adversariales en datasets complejos como *Fashion-MNIST*, MetaSilvae logra incrementar significativamente esta métrica manteniendo niveles comparables de precisión. Este comportamiento demuestra que la arquitectura del ensamblaje influye directamente en la resiliencia estructural del sistema y en su capacidad para mantener el rendimiento bajo condiciones hostiles. [12]

Para escenarios dinámicos, la adaptabilidad se aborda mediante arquitecturas orientadas al procesamiento de flujos de datos, como LAST (*Local Adaptive Streaming Tree*) y GAST (*Global Adaptive Streaming Tree*). A diferencia de los Árboles de Hoeffding convencionales, que evalúan divisiones mediante mecanismos estáticos y periódicos, LAST incorpora detectores de cambio ADWIN en cada nodo hoja para monitorizar continuamente la tasa de error. [12]

Esta capacidad de adaptación permite detectar desplazamientos de concepto (*concept drift*) y activar nuevas divisiones únicamente cuando la distribución de los datos experimenta cambios significativos. Los resultados reportados muestran que LAST supera a algoritmos como HAT (*Hoeffding Adaptive Tree*) y EFDT en múltiples conjuntos de datos reales, optimizando simultáneamente el uso de memoria, CPU y precisión predictiva. [30]

1.4.4. Factores que afectan la precisión

La precisión de un árbol de decisión depende de múltiples factores estructurales y ambientales que interactúan entre sí durante el proceso de aprendizaje. Entre ellos, la profundidad del árbol constituye uno de los elementos más relevantes. Un incremento moderado en la profundidad permite capturar patrones complejos presentes en los datos; sin embargo, una expansión excesiva conduce inevitablemente al sobreajuste (*overfitting*), reduciendo la capacidad de generalización del modelo. [19]

Diversos estudios muestran que superar determinados umbrales de profundidad produce una disminución significativa de la exactitud en conjuntos de prueba, aun cuando la precisión sobre los datos de entrenamiento continúe aumentando. Para mitigar este problema, la poda (*pruning*) se ha consolidado como una técnica fundamental en la construcción de árboles robustos. [19]

Las propuestas más recientes incorporan criterios adicionales de equidad (*fairness*) dentro del proceso de poda. La denominada *fairness-guided pruning* elimina ramas que contribuyen al sesgo discriminatorio manteniendo pérdidas mínimas de exactitud, generalmente inferiores al 5 %. [9] Esta evolución transforma la poda de una herramienta puramente estadística en un mecanismo orientado a la construcción de modelos más responsables y transparentes.

La selección de atributos constituye otro factor determinante. Métodos como Boruta y CFS (*Correlation-based Feature Selection*) permiten eliminar variables redundantes o irrelevantes que incrementan innecesariamente la complejidad del árbol [3, 26]. Los resultados experimentales

muestran mejoras significativas en Accuracy y ROC-AUC tras la reducción del espacio de características, especialmente en dominios con alta dimensionalidad.

En aplicaciones relacionadas con toxicología computacional, la reducción de variables permitió incrementar el área bajo la curva ROC en aproximadamente un 13.8%, evidenciando que la calidad de los atributos utilizados puede resultar más determinante que la complejidad del algoritmo de inducción empleado. [21]

Asimismo, el desbalance de clases representa una fuente importante de degradación del rendimiento. Cuando una categoría domina ampliamente la distribución de los datos, los criterios de partición tienden a favorecer la clase mayoritaria, disminuyendo la sensibilidad hacia los casos minoritarios. Técnicas de sobremuestreo como SMOTE han demostrado incrementar significativamente la precisión y el F1-Score en aplicaciones médicas y de diagnóstico [5].

El ruido y los valores faltantes también afectan negativamente la pureza de los nodos y la estabilidad de las particiones. Diversas investigaciones proponen mecanismos de manejo fraccional de datos o estrategias de imputación que permiten recuperar parte de la precisión perdida debido a la incertidumbre presente en los datos de entrada [5].

Finalmente, factores externos como la privacidad diferencial y el desplazamiento de concepto constituyen desafíos emergentes para los árboles de decisión modernos. La incorporación de ruido para proteger información sensible reduce inevitablemente la utilidad estadística del modelo; sin embargo, propuestas recientes como S-BDT han demostrado que es posible mantener altos niveles de precisión mediante esquemas de ruido balanceado y mecanismos adaptativos de control de privacidad [7, 24].

1.4.5. Síntesis integradora

La evidencia analizada permite concluir que la influencia de los árboles de decisión en la precisión de los sistemas de clasificación no depende exclusivamente del algoritmo utilizado, sino de la interacción entre arquitectura, estrategia de optimización, calidad de los datos y contexto de aplicación. Los resultados revisados muestran que los mayores incrementos de precisión se producen cuando se combinan métodos de optimización global con arquitecturas capaces de modelar relaciones complejas entre atributos [7, 10].

La transición desde enfoques estrictamente voraces hacia modelos optimizados globalmente, como DPDT y TAO, representa uno de los avances más relevantes identificados en la literatura. Estos métodos permiten superar limitaciones históricas asociadas a los óptimos locales y generan árboles más compactos y precisos [7, 10].

De manera complementaria, la incorporación de nodos bivariados y estructuras híbridas contribuye a reducir la profundidad necesaria para representar relaciones complejas, disminuyendo simultáneamente el riesgo de sobreajuste y mejorando la interpretabilidad del modelo [17, 19].

Asimismo, la literatura demuestra que la precisión no debe evaluarse únicamente mediante Accuracy. Métricas como F1-Score, Recall y ROC-AUC ofrecen una visión más completa del rendimiento, particularmente en contextos caracterizados por desbalance de clases o altos costos asociados a errores de clasificación [7, 23].

En consecuencia, la evolución reciente de los árboles de decisión hacia modelos adaptativos, híbridos y resistentes a perturbaciones adversariales garantiza su vigencia frente a alternativas más complejas como el aprendizaje profundo. Su capacidad para combinar interpretabilidad, eficiencia computacional y altos niveles de precisión los mantiene como una de las herramientas más relevantes para la clasificación de datos estructurados en dominios críticos [11, 13].

Tabla 1.2: Comparativa de Modelos Híbridos y su Impacto en la Precisión

Modelo Híbrido	Componentes Integrados	In-	Ventaja Principal en Precisión	Hallazgo Clave
NBTree	Árbol de decisión + Naive Bayes		Reduce la fragmentación de datos en hojas profundas	Alcanzó 84.47 % de Accuracy frente al 81.91 % obtenido por C4.5.
MetaSilvae	Random Forest + Algoritmo Genético		Incrementa la estabilidad frente a perturbaciones adversariales	Presentó una mejora superior al 54 % en estabilidad respecto a Random Forest convencional.
S-BDT	Gradient Boosted Decision Trees + Privacidad Diferencial		Mantiene utilidad predictiva bajo restricciones de privacidad	Reduce entre 30 % y 50 % el consumo del presupuesto de privacidad sin afectar significativamente la precisión.
LAST	Árbol Incremental + ADWIN		Adaptación automática al concept drift	Superó a HAT y EFDT en múltiples conjuntos de datos reales.

Tabla 1.3: Factores Determinantes de la Degradación o Mejora de la Precisión

Factor		Efecto en la Precisión	Estrategia de Mitigación	Impacto Reportado
Profundidad excesiva	ex-	Genera sobreajuste y reduce la capacidad de generalización	Poda (Pruning) y control de profundidad máxima	Mejora significativa del rendimiento en datos de prueba.
Datos faltantes y ruido	y	Provocan particiones sesgadas e inestables	Imputación de datos y manejo fraccional	Incrementos de hasta 9.4 % en Accuracy en aplicaciones toxicológicas.
Desbalance de clases	de	Reduce Recall y F1-Score de la clase minoritaria	SMOTE y técnicas de sobremuestreo	F1-Score superior al 96 % en clasificación médica.
Atributos redundantes	redun-	Incrementan complejidad y riesgo de sobreajuste	Boruta y CFS	Reducción de cientos de atributos a conjuntos compactos manteniendo o mejorando Accuracy.
Concept Drift		Degrada progresivamente la precisión en flujos de datos	LAST, GAST y detectores ADWIN	Mantiene precisión estable en entornos dinámicos.
Privacidad Diferencial	Dife-	La adición de ruido reduce la utilidad del modelo	S-BDT y mecanismos adaptativos de privacidad	Conserva niveles competitivos de Accuracy bajo restricciones de seguridad.

Tabla 1.4: Adaptabilidad de los Árboles de Decisión según la Naturaleza de los Datos

Escenario de Datos	Algoritmo Recomendado	Reco- ción	Criterio de Adapta- ción	Resultado en Precisión
Flujos de datos (Streams)	LAST / GAST		Monitoreo continuo mediante ADWIN	Mayor estabilidad y eficiencia en memoria frente a HAT y EFDT.
Datos encriptados (FHE)	DP-DT / Soft-Step Trees		Aproximaciones polinomiales compatibles con cifrado	Precisión comparable a implementaciones tradicionales de scikit-learn.
Entornos adversariales	MetaSilvae		Optimización genética orientada a robustez	Mayor resiliencia frente a ataques de manipulación de datos.
Problemas altamente no lineales	DPDT		Optimización global mediante MDP	Hasta 100 % de Accuracy en problemas tipo XOR.
Datos médicos desbalanceados	NBTree		Integración de Naive Bayes en hojas	Mejor ROC-AUC y sensibilidad diagnóstica.
Alta dimensionalidad	Bivariate TAO		Combinación de atributos por nodo	Modelos más pequeños y precisos que CART.

1.5. Conclusiones

1. Los árboles de decisión continúan siendo una de las técnicas de clasificación más relevantes dentro del aprendizaje automático debido a su capacidad para combinar interpretabilidad, facilidad de implementación y elevados niveles de precisión. La revisión de la literatura evidenció que su rendimiento depende no solamente del algoritmo utilizado, sino también de factores estructurales como la arquitectura de los nodos, la estrategia de inducción, la calidad de los datos y las técnicas de optimización empleadas.
2. La principal limitación de los algoritmos tradicionales, como ID3, C4.5 y CART, radica en su naturaleza de inducción voraz (*greedy*), la cual puede conducir a soluciones localmente óptimas pero globalmente subóptimas. Los estudios analizados demostraron que enfoques de optimización global como DPDT y TAO logran mejoras significativas en precisión, generalización y compactación estructural, alcanzando incluso resultados óptimos en problemas complejos donde los métodos clásicos presentan limitaciones evidentes.
3. La incorporación de arquitecturas avanzadas, como árboles bivariados, modelos híbridos y métodos adaptativos, constituye uno de los avances más importantes identificados en la literatura reciente. Los árboles bivariados permiten capturar correlaciones entre atributos reduciendo considerablemente el tamaño de los modelos sin sacrificar exactitud, mientras que enfoques híbridos como NBTree, MetaSilvae y LAST mejoran la robustez, la estabilidad y la capacidad de adaptación frente a entornos dinámicos, adversariales o con desplazamiento de concepto.
4. La precisión de los sistemas de clasificación basados en árboles de decisión está fuertemente condicionada por factores externos relacionados con los datos. Elementos como el desbalance de clases, el ruido, los valores faltantes, la profundidad excesiva, la selección de atributos y las restricciones de privacidad pueden afectar significativamente el desempeño del modelo. En consecuencia, las mejores prácticas identificadas combinan técnicas de poda, selección de características, estrategias de balanceo de datos y mecanismos de adaptación continua para maximizar la capacidad predictiva y garantizar resultados confiables en aplicaciones reales.

Referencias

- [1] A. Akavia, M. Leibovich, Y. Resheff, R. Ron, M. Shahar, and M. Vald, “Privacy-preserving decision trees training and prediction,” *ACM Transactions on Privacy and Security*, vol. 25, pp. 1–30, 8 2022, doi: 10.1145/3517197;TAXONOMY:TAXONOMY:ACM-PUBTYPE;PAGEGROUP:STRING:PUBLICATION.
- [2] K. Khatatneh and I. M. M. E. Emary, “Enhancing the performance of entropy algorithm using minimum tree in decision tree classifier,” *Lecture Notes in Electrical Engineering*, vol. 14 LNEE, pp. 333 – 347, 2009, doi: 10.1007/978-1-4020-8919-0_23.
- [3] G. Seeja, A. S. A. Doss, and V. B. Hency, “A novel approach for disaster victim detection under debris environments using decision tree algorithms with deep learning features,” *IEEE Access*, vol. 11, pp. 54 760–54 772, 5 2023, doi: 10.1109/ACCESS.2023.3281461.
- [4] K. Yousef and A. Mahwish, “A fraud detection system using decision trees classification in an online transactions,” *ACM International Conference Proceeding Series*, pp. 212–217, 2 2023, doi: 10.1145/3587828.3587860;WGROU:STRING:ACM.
- [5] Prakash, G. Agrawal, M. D. Borah, V. Kumar, P. D. Kamleshbhai, and P. Kumar, “A comparative analysis of decision tree classifier performance in the medical data analysis,” in *Proceedings - 1st International Conference on Electronics, Communication and Signal Processing, ICECSP 2024*, 2024, doi: 10.1109/ICECSP61809.2024.10698424.
- [6] A. Krishnakumar and U. Y. Ogras, “Performance analysis and optimization of decision tree classifiers on embedded devices: work-in-progress,” in *Proceedings - 2021 International Conference on Embedded Software, EMSOFT 2021*, 2021, pp. 37 – 38, doi: 10.1145/3477244.3477618.
- [7] R. Kairgeldin and M. Carreira, “Bivariate decision trees: Smaller, interpretable, more accurate,” *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1336–1347, 8 2024, doi: 10.1145/3637528.3671903;GROUPTOPIC:TOPIC:ACM-PUBTYPE.
- [8] R. Kohavi, “Scaling up the accuracy of naive-bayes classifiers: A decision-tree hybrid,” in *Proceedings - 2nd International Conference on Knowledge Discovery and Data Mining, KDD 1996*, 1996, pp. 202 – 207.
- [9] M. Bagriacik and F. Otero, “Fairness-guided pruning of decision trees,” *ACMF AccT 2025 - Proceedings of the 2025 ACM Conference on Fairness, Accountability, and Transparency*, pp. 1745–1756, 6 2025, doi: 10.1145/3715275.3732117;WGROU:STRING:ACM.
- [10] H. Kohler, R. Akrou, and P. Preux, “Breiman meets bellman: Non-greedy decision trees with mdps,” *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, vol. 2, pp. 1207–1218, 8 2025, doi: 10.1145/3711896.3736868;PAGE:STRING:ARTICLE/CHAPTER.

- [11] J. Alvarez, K. Scott, B. Berendt, and S. Ruggieri, “Domain adaptive decision trees: Implications for accuracy and fairness,” *ACM International Conference Proceeding Series*, pp. 423–433, 6 2023, doi: 10.1145/3593013.3594008;WGROUP:STRING:ACM.
- [12] F. Ranzato and M. Zanella, “Genetic adversarial training of decision trees,” *GECCO 2021 - Proceedings of the 2021 Genetic and Evolutionary Computation Conference*, pp. 358–367, 6 2021, doi: 10.1145/3449639.3459286;TOPIC:TOPIC:CONFERENCE-COLLECTIONS.
- [13] K. Chen, C. Su, C. Hakert, S. Buschjäger, C. Lee, J. Lee, K. Morik, and J. Chen, “Efficient realization of decision trees for real-time inference,” *ACM Transactions on Embedded Computing Systems*, vol. 21, pp. 1–26, 10 2022, doi: 10.1145/3508019;TAXONOMY:TAXONOMY:ACM-PUBTYPE;PAGEGROUP:STRING:PUBLICATION.
- [14] W. K. Wong, F. H. Juwono, C. Apriono, and I. R. Fitri, “Fetal health prediction from cardiocography recordings using kolmogorov–arnold networks,” *IEEE Open Journal of Engineering in Medicine and Biology*, vol. 6, pp. 345–351, 3 2025, doi: 10.1109/OJEMB.2025.3549594.
- [15] P. Kumar, Nitin, V. Sehgal, and D. S. Chauhan, “Performance evaluation of decision tree versus artificial neural network based classifiers in diversity of datasets,” in *Proceedings of the 2011 World Congress on Information and Communication Technologies, WICT 2011*, 2011, pp. 798 – 803, doi: 10.1109/WICT.2011.6141349.
- [16] Q. Yin, J. Cheng, F. Zhang, Y. Zhou, L. Shao, and W. Hong, “Interpretable polsar image classification based on adaptive-dimension feature space decision tree,” *IEEE Access*, vol. 8, pp. 173 826–173 837, 9 2020, doi: 10.1109/ACCESS.2020.3023134.
- [17] M. W. L. Moreira, J. J. P. C. Rodrigues, N. Kumar, J. Niu, and I. Woungang, “Performance assessment of decision tree-based predictive classifiers for risk pregnancy care,” in *Proceedings - IEEE Global Communications Conference, GLOBECOM*, vol. 2018-January, 2017, pp. 1 – 5, doi: 10.1109/GLOCOM.2017.8254451.
- [18] V.-H. Dang, T. B. Dieu, X.-L. Tran, and N.-D. Hoang, “Enhancing the accuracy of rainfall-induced landslide prediction along mountain roads with a gis-based random forest classifier,” *Bulletin of Engineering Geology and the Environment*, vol. 78, pp. 2835 – 2849, 2019, doi: 10.1007/s10064-018-1273-y.
- [19] M. N. Reddy, M. R. L. Kumar, P. B. S. Kumar, S. Thirumalai, and M. N. Devi, “Performance enhancement by tuning hyperparameters of random forest classifier for hardware trojan detection,” *Lecture Notes in Networks and Systems*, vol. 288, pp. 177 – 191, 2022, doi: 10.1007/978-981-16-5120-5_14.
- [20] F. Zhang, H. He, J. Yu, W. Yu, and F. Deng, “Exploration of news categorization techniques based on cart decision trees,” pp. 126–131, 7 2025, doi: 10.1145/3765416.3765438;WGROUP:STRING:ACM.
- [21] R. Romano, A. Barbul, and R. Korenstein, “From modeling dose-response relationships to improved performance of decision-tree classifiers for predictive toxicology of nanomaterials,” *Computational Toxicology*, vol. 27, 2023, doi: 10.1016/j.comtox.2023.100277.
- [22] H. Ma, J. Cao, Y. Fang, W. Zhang, W. Sheng, S. Zhang, and Y. Yu, “Retrieval-based gradient boosting decision trees for disease risk assessment,” *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 3468–3476, 8 2022, doi: 10.1145/3534678.3539052;PAGE:STRING:ARTICLE/CHAPTER.

- [23] D. Bhardwaj, N. Chandran, S. Saravanan, and D. Gupta, “Securely training decision trees efficiently,” *CCS 2024 - Proceedings of the 2024 ACM SIGSAC Conference on Computer and Communications Security*, pp. 4673–4687, 12 2024, doi: 10.1145/3658644.3670268;CSUBTY-PE:STRING:CONFERENCE.
- [24] T. Peinemann, M. Kirschte, J. Stock, C. Cotrini, and E. Mohammadi, “S-bdt: Distributed differentially private boosted decision trees,” *CCS 2024 - Proceedings of the 2024 ACM SIGSAC Conference on Computer and Communications Security*, pp. 288–302, 12 2024, doi: 10.1145/3658644.3690301;WGROU:STRING:ACM.
- [25] W. H. Xu, Z. Qin, and Y. Chang, “Clustering feature decision trees for semi-supervised classification from high-speed data streams,” *Journal of Zhejiang University: Science C*, vol. 12, pp. 615–628, 8 2011, doi: 10.1631/JZUS.C1000330.
- [26] D. Chutia, N. Borah, D. Baruah, D. K. Bhattacharyya, P. L. N. Raju, and K. K. Sarma, “An effective approach for improving the accuracy of a random forest classifier in the classification of hyperion data,” *Applied Geomatics*, vol. 12, pp. 95 – 105, 2020, doi: 10.1007/s12518-019-00281-8.
- [27] Y. Weiguo, L. Mingyu, and L. Zhi, “Variable precision rough set based decision tree classifier,” *Journal of Intelligent and Fuzzy Systems*, vol. 23, pp. 61 – 70, 2012, doi: 10.3233/IFS-2012-0496.
- [28] S. Alex, K. J. Dhanaraj, and P. P. Deepthi, “Private and energy-efficient decision tree-based disease detection for resource-constrained medical users in mobile healthcare network,” *IEEE Access*, vol. 10, pp. 17 098–17 112, 2, doi: 10.1109/ACCESS.2022.3149771.
- [29] Y. Song, S. Yao, D. Yu, Y. Shen, and Y. Hu, “A new k-ary crisp decision tree induction with continuous valued attributes,” *Chinese Journal of Electronics*, vol. 26, pp. 999–1007, 9 2017, doi: 10.1049/CJE.2017.07.015.
- [30] D. Assis, J. Barddal, and F. Enembreck, “Just change on change: Adaptive splitting time for decision trees in data stream classification,” *Proceedings of the ACM Symposium on Applied Computing*, pp. 351–357, 4 2024, doi: 10.1145/3605098.3635899;WGROU:STRING:ACM.
- [31] J. Zhang, I. Beschastnikh, S. Mechtaev, and A. Roychoudhury, “Fair decision making via automated repair of decision trees,” *Proceedings - International Workshop on Equitable Data and Technology, FairWare 2022*, pp. 9–16, 12 2022, doi: 10.1145/3524491.3527306.